

Използваме ги, за да:

- търсим по-сложна последователност от символи в низ
- заместим такива последователности с нещо друго
- проверим даден низ дали отговаря на определени условия

$\Gamma' \wedge (11+) (\backslash 1) + \$'$

начало

→ край

→ дава ти първата група
в нашия случай $(11+)$

Тоест ползваме:

$\Gamma' \wedge (11+) (11+) \wedge \$'$

→ отнася се за преди него
трябва да са еднакви

- "шаблон" (pattern), още "регулярен израз"
- специални символи
- ескейпване на специалните символи
- квантори и повторения
- класове от символи
- групи
- флагове

Основните
терминологии

import re - модулът, реализиращ регулярните изрази

- escape-ване на специални символи → използваме \
- специалните символи: . / \ () [] { } + | ^ \$ * ?
- \ пред специален символ → прави го неспециален

Повторения - ванат за непосредствено предхождащия ги символ / клас / група

(винаги взима максималните повторения)

- S^* - нула или повече повторения на S
- S^+ - едно или повече повторения на S
- $S?$ - нула или едно повторение
- $S\{m, n\}$ - между m и n повторения
- $S\{, n\}$ - от нула до n повторения
- $S\{m, \}$ - поне m повторения

Non-greedy

- полутаба се с ? след квантора

$1?$ - търси числото 1 нула или един път $\rightarrow$ greedy

$1+?$ - търси единицата един път, така се да удовлетвори израза (минималните повторения)

Скоби () - групи

- групиране на части от шаблона
- можем да се обръщаме към тях и от самия шаблон:
 - 1 - първата група
 - 2 - втората група

Специални символи

- $\cdot$ - съвпада с един произволен символ (символите за нов ред не се включват)
- $\wedge$ - началото на низ
- $\$$ - края на низ

ре (pipe)

- | има смисъл на или
(търси първия мат)

Символни класове

- набор от символи, заградени от `[]`

`[abc]` - съвпада с точно един от символите

- Отрицание на клас - посредством `^` в началото на класа:

`[^CVL]` - да не е C или V или L

↑
относя се за целия клас (до края на `]`)

- диапазони от символи

`[0-9]` - едно съвпадение на числата от 0 до 9

`[a-z]` - едно съвпадение на буквите от a до z

`[A-Z]`

Предефинирани класове

`\d` - една цифра; $\equiv [0-9]$

`\D` - символ, който не е цифра; $\equiv [^0-9]$

`\s` - един whitespace символ; $\equiv [\t\r\n\f\v]$

`\S` - един символ, който не е whitespace; $\equiv [^ \t\r\n\f\v]$

`\w` - една буква или цифра

`\W` - един символ, който не е буква или цифра

`\b` - нула символа, но граница на дума

`\B` - нула символа, не е граница на дума

`\s` използва се, ако искате в дума да померим поддума)

Методи на re

`re.search()` - проверява дали стринга съдържа текст, отговарящ на шаблона, връща `re.Match` обект

`re.match()` - търси се в началото на низа, (тоест се връща първото срещнато)

`re.findall()` - списък от всички съвпадения на шаблона

`re.finditer()` - връща итератор

`re.Match` обектите съдържат подробна информация за групите, които сме направили

Методи на re.Match обектите

`group()` - връща частта от низа, отговаряща на шаблона

`groups()` - tuple от ^{групите} ~~низове на match-овете~~

`start()` - връща началото на съвпаденията (индекс)

`end()` - връща края на съвпаденията (индекс)

`span()` - връща `(start, end)` като tuple

Implosion

- `(?: ...)` - използване на скоби, без да се създава група
- `(?P<name> ...)` - текстът, отговарящ на групата, може да бъде достъпван чрез име
- `(?P= name)` - търси съвпадение на текста, намерен по-рано от групата, кръстена `name`
- `(?# ...)` - коментар, игнорира се
- `(?= ...)` - съвпадение, ако... следва (look-ahead)
- `(?! ...)` - съвпадение, ако... не следва (negative look-ahead)
- `(?<= ...)` - съвпадение, ако стои преди следващата част от шаблона (look-behind)
- `(?<= ...)` - съвпадение, ако стои преди следващата част от шаблона
- `(?(id/name) yes|no)` - търси за шаблона `yes`, ако групата с номер/име съвпадне

Методи на re

- `re.sub(pattern, repl, string, count=0)` - заместване в низ, на база на шаблон
- `re.split(pattern, string, maxsplit=0)` - разделяне на низ на парчета, на база на шаблон
- `re.escape(pattern)` - *escape* - ва всички специални за регулярен израз символи
- `help(re)`

Флагове

- `re.I` (`re.IGNORECASE`) - case-insensitive търсене
- `re.L` (`re.LOCALE`) - кара `\w`, `\W`, `\b`, `\B` зависят от текущия locale
- `re.M` (`re.MULTILINE`) - кара `^` съвпада с началото на низ или началото на ред, `$` - с край на ред или край на низ.
- `re.S` (`re.DOTALL`) - `.` съвпада с всеки символ, включително и нов ред
- `re.X` (`re.VERBOSE`) - режим на игнориране на whitespace и коментари
- `re.A` (`re.ASCII`) - кара `\w`, `\W`, `\b`, `\B`, `\d`, `\D` да отговарят на съответните ASCII класове